빅데이터분석프로그래밍_타이타닉_과제

데이터 분석을 통해 알고자하는 내용

- 생존율이 가장 높은 동승 인원 수
- 각 동승 인원 수의 그룹 별 생존율 -> 위 내용을 분석하다 보니 궁금해져서 분석하게 됨

설정

파이썬 설치 확인

In [1]:
```
import sys
import pandas as pd
import numpy as np

print(sys.version)
print(pd.__version__)
print(np.__version__)
```

```
3.10.12 (main, Nov 20 2023, 15:14:05) [GCC 11.4.0]
2.0.3
1.25.2
```

코랩에서 한글 처리

In [2]:
```
!pip install koreanize_matplotlib
```

```
Collecting koreanize_matplotlib
  Downloading koreanize_matplotlib-0.1.1-py3-none-any.whl (7.9 MB)
     ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 7.9/7.9 MB 17.0 MB/s eta 0:00:00
Requirement already satisfied: matplotlib in /usr/local/lib/python3.10/dist-packages (from koreanize_matplotlib) (3.7.1)
Requirement already satisfied: contourpy>=1.0.1 in /usr/local/lib/python3.10/dist-packages (from matplotlib->koreanize_matplotlib) (1.2.1)
Requirement already satisfied: cycler>=0.10 in /usr/local/lib/python3.10/dist-packages (from matplotlib->koreanize_matplotlib) (0.12.1)
Requirement already satisfied: fonttools>=4.22.0 in /usr/local/lib/python3.10/dist-packages (from matplotlib->koreanize_matplotlib) (4.52.4)
Requirement already satisfied: kiwisolver>=1.0.1 in /usr/local/lib/python3.10/dist-packages (from matplotlib->koreanize_matplotlib) (1.4.5)
Requirement already satisfied: numpy>=1.20 in /usr/local/lib/python3.10/dist-packages (from matplotlib->koreanize_matplotlib) (1.25.2)
Requirement already satisfied: packaging>=20.0 in /usr/local/lib/python3.10/dist-packages (from matplotlib->koreanize_matplotlib) (24.0)
Requirement already satisfied: pillow>=6.2.0 in /usr/local/lib/python3.10/dist-packages (from matplotlib->koreanize_matplotlib) (9.4.0)
Requirement already satisfied: pyparsing>=2.3.1 in /usr/local/lib/python3.10/dist-packages (from matplotlib->koreanize_matplotlib) (3.1.2)
Requirement already satisfied: python-dateutil>=2.7 in /usr/local/lib/python3.10/dist-packages (from matplotlib->koreanize_matplotlib) (2.8.2)
Requirement already satisfied: six>=1.5 in /usr/local/lib/python3.10/dist-packages (from python-dateutil>=2.7->matplotlib->koreanize_matplotlib) (1.16.0)
Installing collected packages: koreanize_matplotlib
Successfully installed koreanize_matplotlib-0.1.1
```

In [3]:
```
%config InlineBackend.figure_format = 'retina'
```

In [4]:
```
import matplotlib.pyplot as plt
import koreanize_matplotlib

plt.plot([-10, 5, -3, 1])
plt.title('그래프 제목')
plt.xlabel('직선')
plt.show()
```

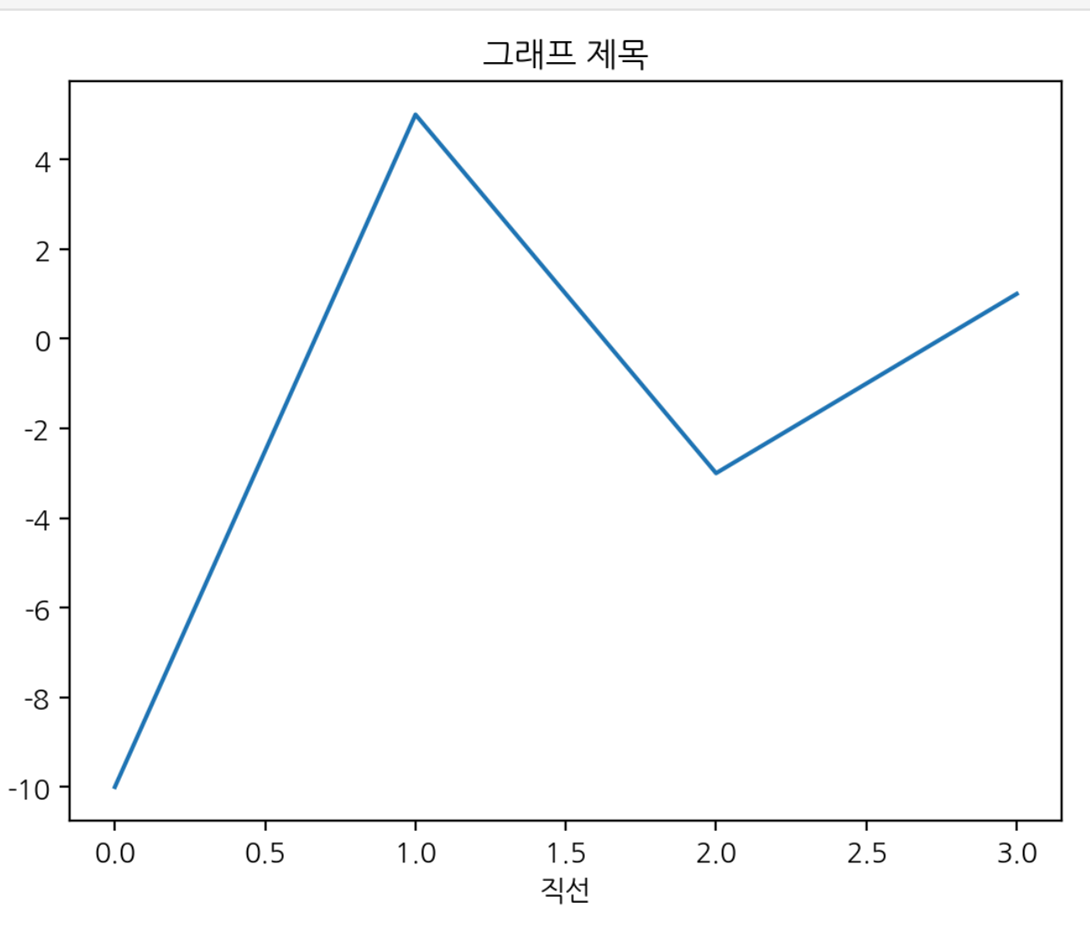

분석 시작

In [5]:
```
# 분석할 타이타닉 데이터 불러오기
import seaborn as sns

titanic = sns.load_dataset("titanic")
```

In [6]:
```
# 분석 내용 선정을 위해
# 타이타닉 데이터 변수 확인
titanic.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 15 columns):
 #   Column       Non-Null Count  Dtype   
---  ------       --------------  -----   
 0   survived     891 non-null    int64   
 1   pclass       891 non-null    int64   
 2   sex          891 non-null    object  
 3   age          714 non-null    float64 
 4   sibsp        891 non-null    int64   
 5   parch        891 non-null    int64   
 6   fare         891 non-null    float64 
 7   embarked     889 non-null    object  
 8   class        891 non-null    category
 9   who          891 non-null    object  
 10  adult_male   891 non-null    bool    
 11  deck         203 non-null    category
 12  embark_town  889 non-null    object  
 13  alive        891 non-null    object  
 14  alone        891 non-null    bool    
dtypes: bool(2), category(2), float64(2), int64(4), object(5)
memory usage: 80.7+ KB
```

타이타닉 열(변수) 설명

- survived : 0 = 사망, 1 = 생존
- pclass : 1 = 1등석, 2 = 2등석, 3 = 3등석
- sex : male = 남성, female = 여성
- age : 나이
- sibsp : 타이타닉 호에 동승한 자매 / 배우자의 수
- parch : 타이타닉 호에 동승한 부모 / 자식의 수
- fare : 티켓 요금
- embarked : 탑승지, C = 셰르부르, Q = 퀸즈타운, S = 사우샘프턴
- class : First = 1등석, Second = 2등석, Third = 3등석
- who : 남/여/아이, 'man', 'woman', 'child'
- adult_male : 남자 어른, True/False
- deck : 방 위치, 'A', 'B', 'C', 'D', 'E', 'F', 'G', NaN
- embark_town : 탑승지
- alive : 생존, yes/no
- alone : 1인 탑승, True/False

In [7]:
```
# 각 승객의 동승 인원 수를 알아내기 위해
# sibsp, parch, alone 합치기
titanic = titanic.assign(companions = lambda x: x['alone'] + x['parch'] + x['sibsp'])
```

1. 생존율이 가장 높은 동승 인원 수

동승 인원 별 탑승자 수 그래프

In [8]:
```
# 각 승객의 동승 인원 수 확인
titanic['companions'] \
        .value_counts() \
        .to_frame() \
        .sort_values(by='companions')
```

Out[8]:

	count
companions	
1	698
2	102
3	29
4	15
5	22
6	12
7	6
10	7

In [9]:
```
# countplot으로 동승 인원 별 탑승자 수 그래프 그리기
plot_passengers = sns.countplot(data=titanic, x="companions", hue="companions");

# y축 이름 승객으로 변경
plot_passengers.set_ylabel('passengers')

# 그래프 제목 지정
plt.title('동승 인원 별 탑승자 수')

# 그래프 출력
plt.show()
```

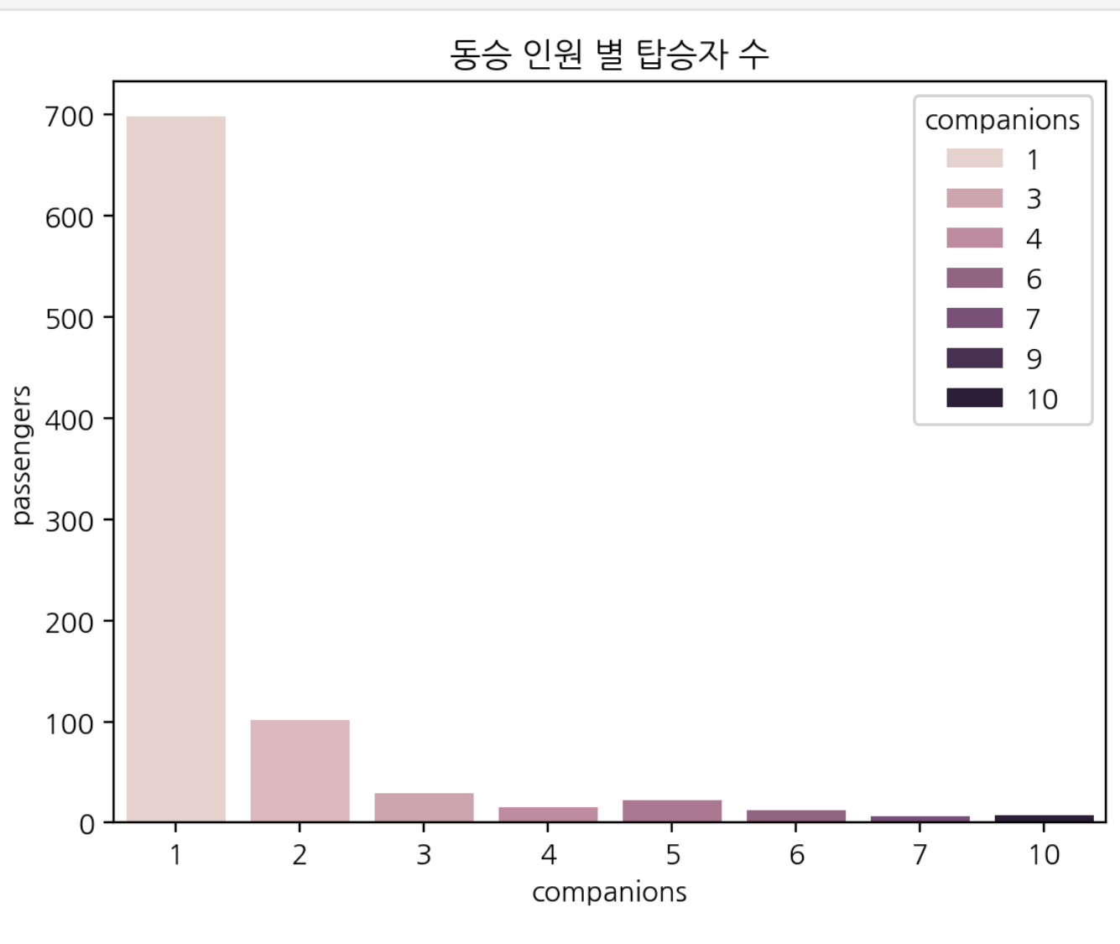

동승 인원 별 생존자 수 그래프

In [10]:
```
# 각 승객의 동승 인원 별 생존자 수 확인
titanic.query('survived==1')['companions'] \
        .value_counts() \
        .to_frame() \
        .sort_values(by='companions')
```

Out[10]:

	count
companions	
1	252
2	59
3	21
4	3
5	3
6	4

In [11]:
```
# 생존 했을 경우만 변수로 만들기
survived = titanic.query('survived == 1')

# countplot으로 동승 인원 별 생존자 수 그래프 그리기
plot_survivors = sns.countplot(data=survived, x='companions', hue='companions');

# y축 이름 생존자로 변경
plot_survivors.set_ylabel('survivors')

# 그래프 제목 지정
plt.title('동승 인원 별 생존자 수')

# 그래프 출력
plt.show()
```

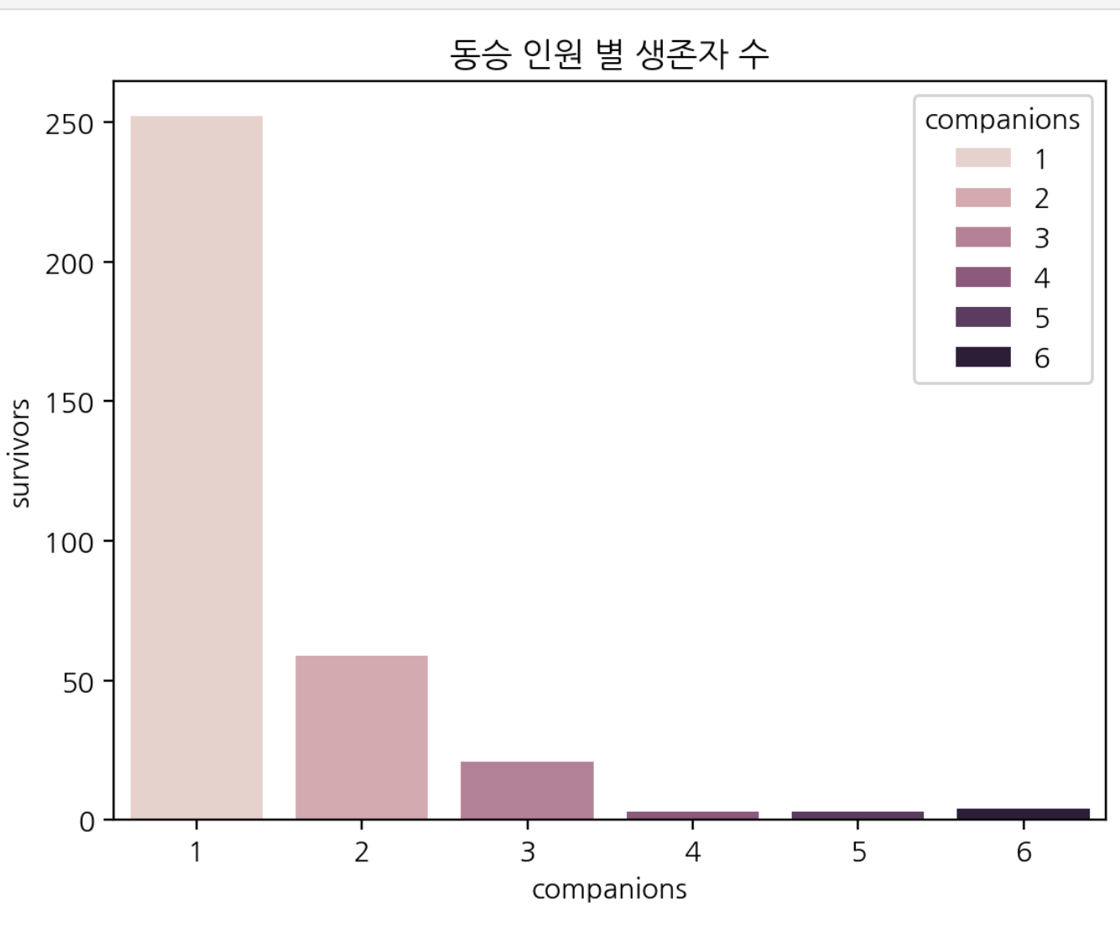

동승 인원 별 생존율 그래프, 결과

In [12]:
```
# 동승 인원 별 생존율 계산
companions_survived_pct = ((titanic.query('survived==1')['companions'].value_counts()) / (titanic['companions'].value_counts()) *100).to_frame()

# barplot으로 동승 인원 별 생존율 그래프 그리기
plot_survivors = sns.barplot(data=companions_survived_pct, x='companions', y='count', hue='companions');

# y축 이름 퍼센트로 변경
plot_survivors.set_ylabel('percent')

# 그래프 제목 지정
plt.title('동승 인원 수 생존율')

# 그래프 출력
plt.show()

# 결과
print("\n결과:")
print("동승자가 3명일 경우 생존율이 가장 높았다.")
print("그리고 동승 인원 수 6명을 이상치로 본다면")
print("동승 인원 수가 2, 3명일 때 생존율이 높다고 볼 수 있다.")
print()
print("왜 이러한 결과가 나왔는지 추측해보자면")
print("동승자가 1, 2명 정도일 때는 구할 사람이 적어 생존율이 높고")
print("동승자가 3, 4명일 때는 구할 사람이 많아 오히려 생존율이 낮다고 추측할 수 있다.")
```

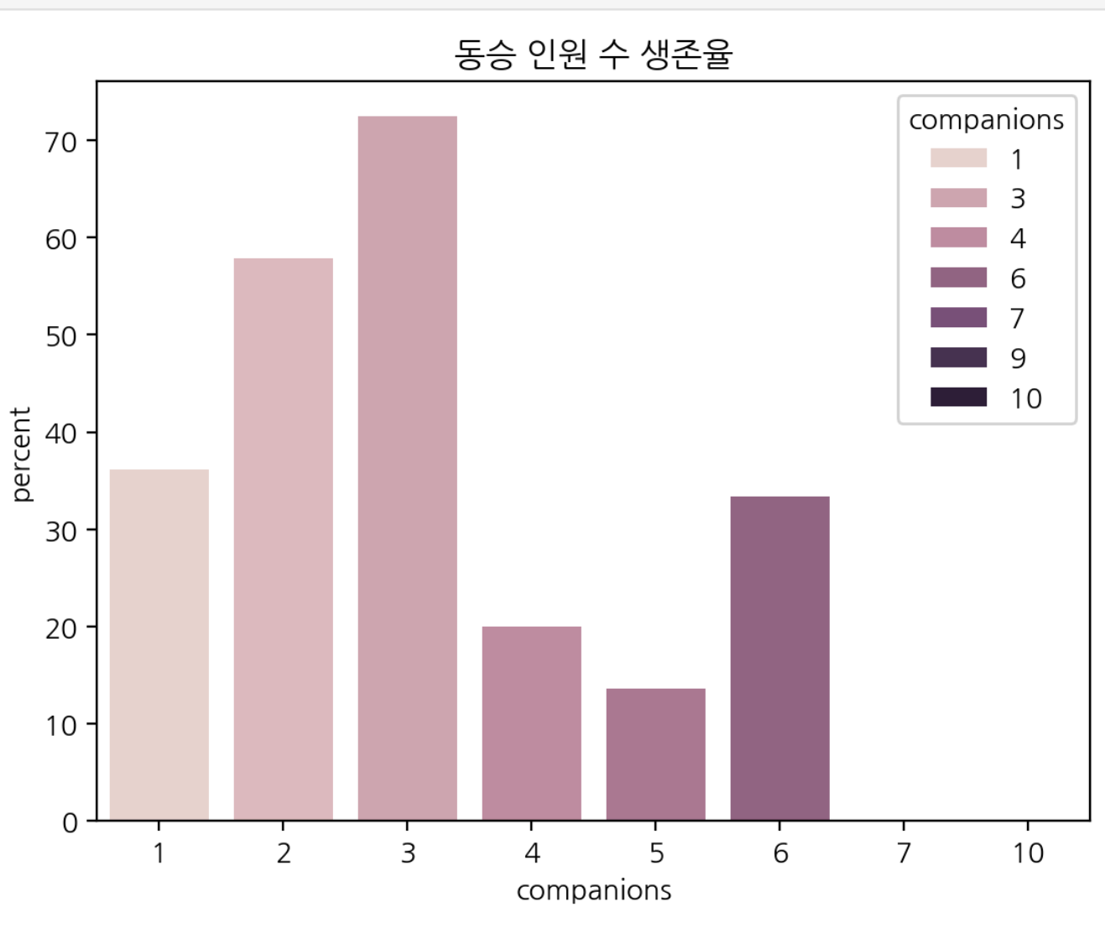

```
결과:
동승자가 3명일 경우 생존율이 가장 높았다.
그리고 동승 인원 수 6명을 이상치로 본다면
동승 인원 수가 2, 3명일 때 생존율이 높다고 볼 수 있다.

왜 이러한 결과가 나왔는지 추측해보자면
동승자가 1, 2명 정도일 때는 구할 사람이 적어 생존율이 높고
동승자가 3, 4명일 때는 구할 사람이 많아 오히려 생존율이 낮다고 추측할 수 있다.
```

2. 각 동승 인원 수의 그룹 별 생존율

동승 인원, 그룹 별 탑승자 수 그래프

In [13]:
```
# 동승 인원, 그룹 별 탑승자 수 확인
titanic.groupby('companions')['who'] \
        .value_counts() \
        .to_frame()
```

Out[13]:

		count
companions	**who**	
1	**man**	481
	woman	198
	child	19
2	**man**	39
	woman	39
	child	24
3	**child**	12
	woman	11
	man	6
4	**woman**	9
	child	4
	man	2
5	**child**	12
	woman	6
	man	4
6	**child**	8
	woman	3
	man	1
7	**child**	4
	woman	2
10	**man**	4
	woman	3

In [14]:
```
# 동승 인원, 그룹 별 탑승자 수 그래프 그리기
plot_passengers = sns.countplot(data=titanic, x="companions", hue="who");

# y축 이름 승객으로 변경
plot_passengers.set_ylabel('passengers')

# 그래프 제목 지정
plt.title('동승 인원, 그룹 별 탑승자 수')

# 그래프 출력
plt.show()
```

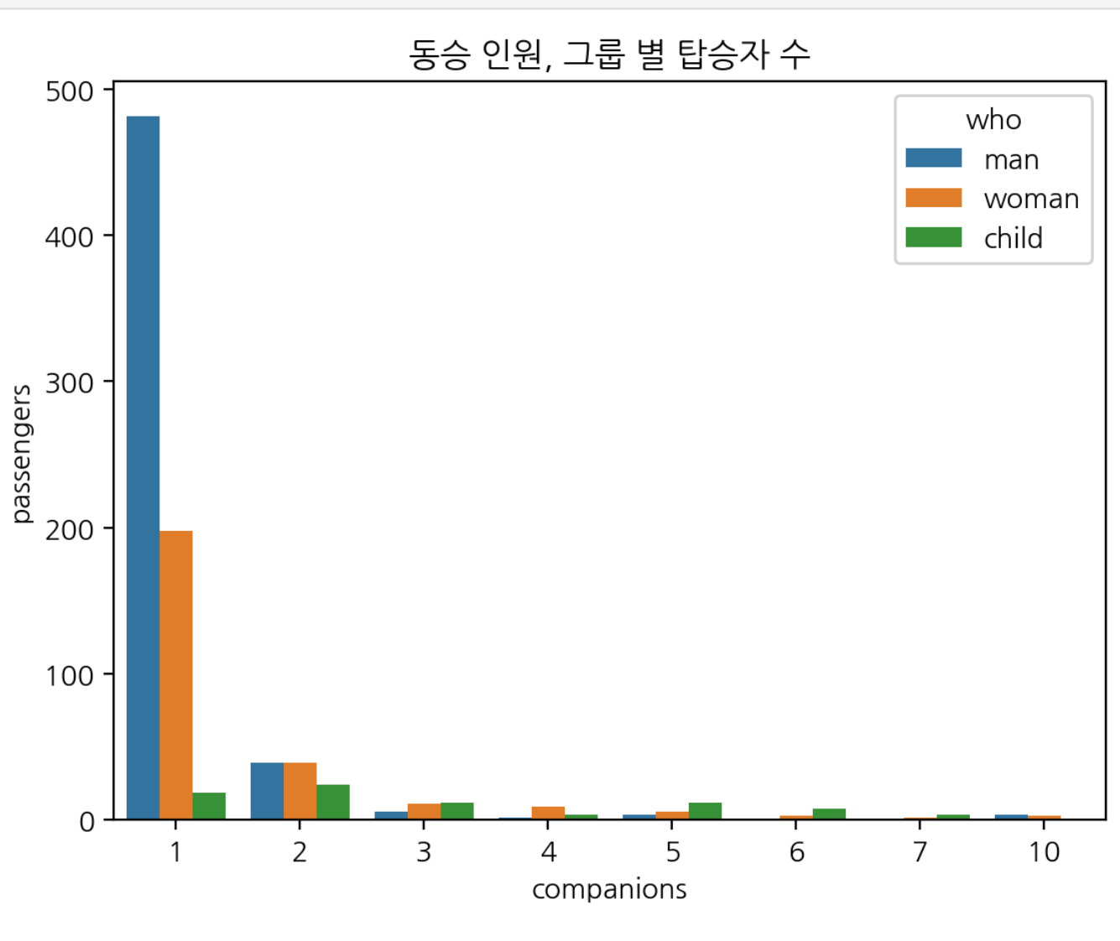

동승 인원, 그룹 별 생존자 수 그래프

In [15]:
```
# 동승 인원, 그룹별 생존자 수 확인
titanic.query('survived==1') \
        .groupby('companions')['who'] \
        .value_counts() \
        .to_frame()
```

Out[15]:

		count
companions	**who**	
1	**woman**	158
	man	79
	child	15
2	**woman**	30
	child	21
	man	8
3	**child**	11
	woman	9
	man	1
4	**woman**	3
5	**woman**	3
6	**child**	2
	woman	2

In [16]:
```
# 생존 했을 경우만 변수로 만들기
survived = titanic.query('survived == 1')

# 동승 인원, 그룹별 생존자 수 그래프 그리기
# 위 그래프와 who 색상을 동일 유지 하기 위해 hue_order=['man', 'woman', 'child'] 추가
plot_survivors = sns.countplot(data=survived, x='companions', hue='who', hue_order=['man', 'woman', 'child']);

# y축 이름 생존자로 변경
plot_survivors.set_ylabel('survivors')

# 그래프 제목 지정
plt.title('동승 인원 별 생존자 수')

# 그래프 출력
plt.show()
```

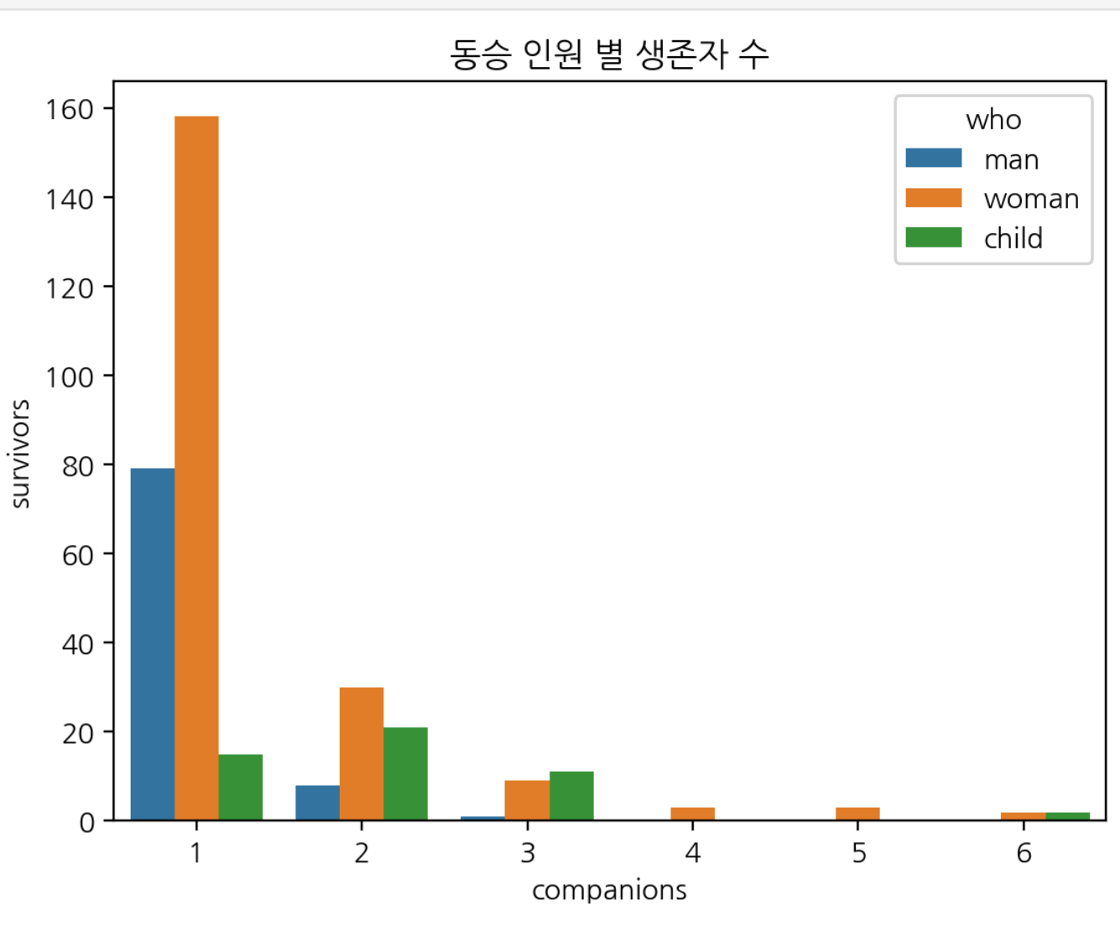

동승 인원, 그룹 별 생존율 그래프, 결과

In [17]:
```
# 동승 인원, 그룹 별 생존율 계산
companions_group_survived_pct = ((titanic.query('survived==1').groupby('companions')['who'].value_counts()) /
                                          (titanic.groupby('companions')['who'].value_counts())*100).to_frame()


# 위 그래프와 who 색상을 동일 유지 하기 위해 hue_order=['man', 'woman', 'child'] 추가
plot_survivors = sns.barplot(data=companions_group_survived_pct, x='companions', y='count', hue='who', hue_order=['man', 'woman', 'child']);

# y축 이름 확률로 변경
plot_survivors.set_ylabel('percent')

# 그래프 제목 지정
plt.title('동승 인원, 그룹 별 생존율')

# 그래프 출력
plt.show()

# 결과
print("\n결과:")
print("2, 3에서는 아이의 생존율이 높았고, 나머지는 여성의 생존율이 높다.")
print("모든 동승 인원 수에서 공통 적으로 여성, 아이의 생존율이 높다.")
print("하지만 두 그룹에서도 여성의 생존율이 더 높은 것을 볼 수 있다.")
print()
print("왜 이러한 결과가 나왔는지 추측해보자면")
print("구하는 사람이 많이 죽고 구해지는 사람이 많이 살아남았다고 생각하는데")
print("그렇게 보면 상대적으로 아이, 여성 보다 남성이 구하는 역할을 많이 맡았다고 볼 수 있다.")
```

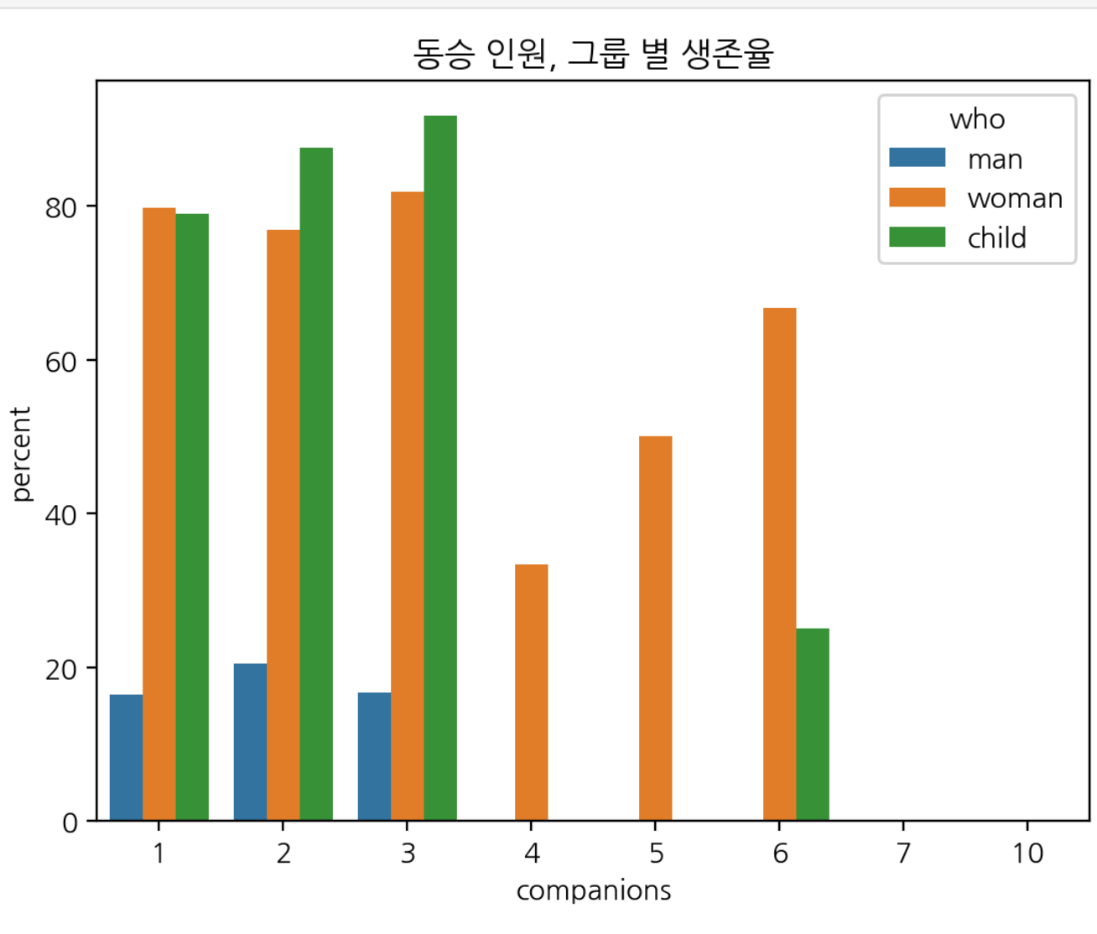

```
결과:
2, 3에서는 아이의 생존율이 높았고, 나머지는 여성의 생존율이 높다.
모든 동승 인원 수에서 공통 적으로 여성, 아이의 생존율이 높다.
하지만 두 그룹에서도 여성의 생존율이 더 높은 것을 볼 수 있다.

왜 이러한 결과가 나왔는지 추측해보자면
구하는 사람이 많이 죽고 구해지는 사람이 많이 살아남았다고 생각하는데
그렇게 보면 상대적으로 아이, 여성 보다 남성이 구하는 역할을 많이 맡았다고 볼 수 있다.
```